

법률 상담 AI

The Legal Consultation AI

김 지 환*, 김 두 한*, 김 민 석*, 신 영 훈*, 김 희 철*
(Ji-hwan Kim, Doo-han Kim, Min-seok Kim, Young-hoon shin, Hie-cheol Kim)

요 약

일반적인 전문 변호사와의 법률상담은 30분을 기준으로 약 5만 원에서 10만 원 내외의 비용이 발생하거나 무료로 상담을 지원해 주는 기관이 존재한다. 하지만 변호사를 선임하여 사건을 진행할 경우 최소 100만 원에서 수백만 원 이상의 고액 선임료가 요구된다. 이러한 높은 비용과 시간적 제약은 법률 서비스를 이용하려는 개인에게 현실적인 부담으로 작용한다. 본 논문에서는 대규모 언어모델(LLM)을 활용한 AI 법률 상담 시스템을 제안하여 이러한 한계를 완화하고자 한다. 본 연구의 작품은 민사법을 중심으로 LLama 3.1 모델을 파인튜닝(Fine-Tuning)하여 사용자의 질의에 대해 법적 자문과 해결방안을 온라인으로 제시한다. 이를 통해 기존 법률상담의 접근성을 향상시키고, 비용 및 시간적 제약을 최소화하여 보다 효율적인 법률 서비스 제공을 가능하게 한다. 나아가 본 시스템은 실시간 상담 기능과 사례 기반 응답을 결합하여, 법률적 판단의 신뢰성과 사용자 만족도를 동시에 향상시키는 것을 목표로 한다.

Abstract

Legal consultations with professional attorneys typically cost around 50,000 to 100,000 KRW for a 30-minute session, and attorney retainer fees for handling a case in court generally range from 1,000,000 KRW to several million won. Such high costs and time constraints often pose significant barriers for individuals seeking legal assistance. This study proposes an AI-based legal consultation system utilizing a Large Language Model (LLM) to address these limitations. The proposed system fine-tunes the LLama 3.1 model based on civil law to provide users with online legal advice and potential solutions to their legal issues. By minimizing the financial and temporal burdens associated with traditional legal services, this approach enhances accessibility and efficiency in legal consultation. Furthermore, the system integrates real-time interaction with case-based responses to improve both the reliability of legal reasoning and user satisfaction.

I. 서 론

한국가정법률상담소의 2024년 통계에 따르면, 한 해 동안 총 53,473건의 법률상담이 이루어졌으며, 그중 면접상담이 21,100건, 전화상담이 31,135건, 인터넷상담이 1,145건으로 집계되었다. 특히 면접상담 부문에서 가사

및 민사사건이 21,929건(98.4%)을 차지해, 대부분의 법률상담이 전문 상담원 또는 변호사와의 직접 상담을 통해 이루어지고 있음을 알 수 있다 [1].

이처럼 전통적인 법률상담은 상담 인력과 공간에 의존하기 때문에 시간적·공간적 제약이 불가피하다. 상담을 원하는 이용자는 근무시간 이외의 시간대에는 상담을 받을 수 없으며, 면접상담의 경우 변호사 사무실이나

상담소를 직접 방문해야 한다. 이러한 구조적 한계로 인해 이용자는 상담 대기시간이 길어지고, 지역 간 법률서비스 접근성 격차가 발생한다. 또한, 온라인에서도 법률상담 플랫폼이나 단순 챗봇 기반의 상담 시스템이 일부 존재하지만, 이들은 대부분 사전 정의된 키워드 검색 기반이거나 규칙형 응답 시스템에 머물러 있다. 따라서 복잡한 질의나 문맥을 이해하지 못하고, 사용자가 의도한 법률적 의미를 정확히 해석하지 못하는 한계가 있다.

본 논문에서는 대규모 언어모델(LLM) 중 하나인 Llama 3.1 모델을 활용한 지능형 법률상담 시스템을 구현하여 사용자의 질문을 자연어로 이해하고 적절한 법률적 답변을 생성할 수 있도록 설계하고 기존 오프라인 법률상담의 시간적·경제적 제약을 극복하여 보다 접근성이 높고 효율적인 법률서비스를 제공하는 것을 목표로 구현한다.

II. 본론1

1. 개발 및 실험 환경

본 연구에서는 소프트웨어 구현을 기반으로 한 실험 수행에 중점을 두었으며, 실제 공사장과 같은 현장 환경에서의 하드웨어 구축보다는 연구 및 개발 편의성을 고려하였다. 시스템 구현과 모델 학습은 구글에서 제공하는 클라우드 기반 Jupyter Notebook 환경인 Google Colab에서 진행하였다. 특히, 학습에 필요한 고성능 연산을 위해 Colab Pro에서 제공하는 NVIDIA A100 GPU를 활용하였으며, 이를 통해 대규모 데이터 처리 및 모델 학습을 효율적으로 수행할 수 있었다. 이러한 환경은 별도의 고가 하드웨어 없이도 안정적인 모델 학습과 반복적인 실험 수행을 가능하게 하였다.

표 1은 작품에 사용된 패키지 목록과 SW에 대한

정보이다.

표 1. SW 구성

SW 환경	
모델 학습 환경	Google Colab Pro
적용 딥러닝 모델	LLama3.1
설치 SW/패키지 요구사항	- 파이썬 버전: python3.10 - 프레임워크: pytorch, torchvision - 모델 가속 라이브러리: unsloth - 데이터관리: pandas, datasets

2. Llama3.1

1) 모델 구조

본 연구에서 사용한 모델은 Transformer 기반의 대규모 언어 모델(Large Language Model, LLM)구조를 기반으로 한다. 전체 구조는 입력 임베딩(Input Embedding), Self-Attention, Feedforward Network, 그리고 출력 토큰 생성(Output Generation)단계로 구성되어 있다.

먼저, 사용자가 입력한 문장은 토큰화(Tokenization)과정을 통해 단어 또는 서브워드 단위의 텍스트 토큰(Text Token)으로 변환된다. 이후 각 토큰은 임베딩(Embedding) 레이어를 거쳐 고정된 차원의 벡터 표현(Token Embedding)으로 변환되며, 이 임베딩은 모델의 입력으로 사용된다.

다음 단계에서는 Self-Attention 메커니즘이 적용된다. Self-Attention은 입력 시퀀스 내 각 단어가 문맥적으로 어떤 단어에 주목해야 하는지를 학습하여, 문장 내 의미적 관계를 효과적으로 파악한다. 이로써 모델은 긴 문장이나 복잡한 문맥에서도 단어 간의 상호 의존성을 반영할 수 있다.

Self-Attention 이후에는 Feedforward Network가 배치되어, Attention에서 추출된 정

보를 비선형적으로 변환함으로써 모델의 표현력을 향상시킨다. 이러한 Attention과 Feedforward 블록은 여러 층으로 반복되며, 계층이 깊어질수록 더 복잡한 의미적 패턴을 학습하게 된다.

최종적으로, 모델은 오토리그레시브 디코딩(Autoregressive Decoding)방식을 통해 다음 단어를 순차적으로 예측하고 생성한다. 이전에 생성된 단어들을 다시 입력으로 사용하여 문맥적으로 일관된 문장을 완성해 나가는 구조이다.

본 연구에서는 이러한 Transformer 기반 구조를 활용하여, 법률 질의응답 데이터를 학습하고 사용자의 입력 문장에 대해 적절한 법률 상담 문장이나 판례 관련 답변을 생성하도록 모델을 설계하였다.




그림 1. Llama3.1 모델 구조

3) 모델 별 성능 차이

아래 그래프는 Llama 2 7B, Llama 3 8B, Mistral 7B, Gemma 7B 모델 간의 주요 성능을 비교한 결과를 나타낸 것이다. 평가 항목은 일반적 언어 능력(General), 상식적 추론(Common sense), 지식 기반(Knowledge), 수학 및 논리적 추론(Math and Reasoning), 독해력(Reading Comprehension), 코드 생성(Code)등으로 구성된다.

그래프에서 볼 수 있듯이, Llama 3 8B 모델은 전반적인 모든 항목에서 Llama 2 7B, Mistral 7B, Gemma 7B보다 우수한 성능을 보였다. 특히 지식(Knowledge)상식(Common sense)영역에서 가장 높은 품질 점수를 기록하였으며, 이는 학습 데이터의 확장과 향상된 어텐션 메커니즘의 영향으로 해석된다. 또한 수학적 추론(Math and Reasoning)코드

생성(Code)영역에서도 Llama 3 8B는 타 모델보다 균형 잡힌 성능을 보이며, 복잡한 논리적 사고나 프로그램적 응답이 필요한 작업에서도 강점을 나타냈다. 반면 Mistral 7B와 Gemma 7B는 일부 항목에서 준수한 결과를 보였으나, 전반적인 언어 이해력과 추론력 측면에서는 Llama 3 8B에 미치지 못하였다. 이러한 결과를 종합할 때, Llama 3.1 8B 모델은 동일한 파라미터 규모(약 80억 매개변수)를 유지하면서도 이전 세대 및 동급 모델 대비 언어 이해력, 추론 능력, 지식 응용력등 전반적인 성능이 향상된 것을 확인할 수 있다.

따라서 본 연구에서는 법률 상담 및 모의 재판 시스템의 언어 이해와 논리적 추론 성능을 극대화하기 위해 Llama 3.1 8B 모델을 선택하였다. 해당 모델은 제한된 연산 자원에서도 안정적으로 동작하면서, 법률 문서와 같은 복잡한 문맥을 효과적으로 처리할 수 있다는 점에서 본 연구 목적에 가장 적합한 선택으로 판단된다.




그림 2. 모델 별 성능차이

3. LoRA & SFTTrainer

LoRA는 Llama 3.1과 같은 대규모 언어 모델을 미세 조정할 때 활용되는 효율적인 학습 기법이다. 본 기법은 Low-Rank 분해를 적용하여 학습 시 필요한 연산량과 자원 사용을 크게 감소시키는 것을 목표로 한다.

그림 3. 학습구성에서 알 수 있듯이 LoRA는 기존 모델의 가중치 행렬 W 를 저차원(낮은 순위) 형태로 분해한 두 개의 행렬 A 와 B 를 통해 학습을 진행한다. 이때 학습 과정에서는 전체 가중치가 아닌, Low-Rank로 분리된 작은 규모의 행렬 A 와 B 만을 미세 조정하게 되므로, 기존 Fine-Tuning 방식에 비해 계산 복잡도와 메모리 사용량을 효과적으로 줄일 수 있다. 따라서 LoRA는 기존의 전체 파라미터 학습 기반 Fine-Tuning보다 효율적이며, 경량화된 구조로도 높은 성능을 유지할 수 있는 개선된 접근 방식이라 할 수 있다.




그림 3. 학습 구성

이와 함께, SFTTrainer는 Hugging Face에서 제공하는 Fine-Tuning 지원 프레임워크로, LoRA 기법과 결합하여 대규모 언어 모델의 미세 조정 과정을 한층 효율적으로 수행할 수 있도록 설계되었다. 본 기술은 특히 법률 데이터와 같은 소규모 도메인 특화 데이터셋을 Llama 3.1과 같은 대규모 언어 모델에 적용할 때 유용하다. SFTTrainer는 모델 구조, 학습률, 최적화 알고리즘 등 주요 하이퍼파라미터를 세밀하게 조정할 수 있는 기능을 통해 Fine-Tuning의 안정성과 성능을 동시에 확보할 수 있다.

4. 학습 데이터 구축

Instruction Tuning

Instruction Tuning은 학습 데이터를 구성하는 방식으로, 사전학습을 마친 언어 모델이 단순히 다음 단어를 예측하는 수준을 넘어, 사용자의 명령어를 이해하고 이에 따라 응답하도록 학습시키는 기법이다. 기존의 Fine-Tuning된 사전학습 모델은 주어진 문맥에서 확률적으로 다음 단어를 예측하는 데 초점을 맞추기 때문에, 사용자의 지시나 의도를 정확히 반영하는 데 한계가 있다. 반면, Instruction Tuning은 ‘지시어-응답’ 형태의 데이터셋을 추가로 학습시켜 모델이 자연어로 주어진 명령을 이해하고 이에 맞는 출력을 생성할 수 있도록 설계된다. 이러한 학습 과정을 통해 모델은 다양한 형태의 사용자 지시에 대해 높은 일반화 성능을 보이며, 실제 대화나 질의응답과 같은 상호작용 상황에서도 보다 자연스럽게 일관된 응답을 제공할 수 있다. 그림 4.는 기존 Fine-tuning과 어떤 점이 다른지 확인할 수 있는 그림이다.




Figure 2: Comparing instruction tuning with pretrain–finetune and prompting.

그림 4. pretrain-finetune, prompting, instruction tuning에 대한 비교

본 연구에서는 한국어 법률 질의응답 데이터를 기반으로 Instruction Tuning을 위한 학습용 데이터셋을 구축하였다. 원본 데이터셋은 Hugging Face에서 제공하는 한국어 법률 질문 - 답변 자료를 활용하였으며, 전처리 과정에서 질문과 직접적인 관련이 없는 사연, 공감 문구, 이모티콘 등 학습에 불필요한 텍스트 요소를 제거하였다. 이러한 과정

을 통해 모델이 법률 질의응답의 핵심 정보에 집중하여 학습할 수 있도록 데이터 품질을 향상시켰다.

표 2는 Instruction Tuning을 통해 구축된 최종 법률 상담 질문 데이터셋의 예시이며, 총 56,358개 세트의 질의응답 데이터를 포함하고 있다

표2. Instruction Tuning 데이터셋 예시

Instruction	output
양육권 소송 문의로드립니다...(중략) 법적으로 해결하려면 어떻게해야 하는지 문의드립니다.	협의이혼을 하기 위해서는 배우자와 재산분할, 양육권에 대한 협의가 이뤄진다면 이혼이 가능합니다...(생략)
이혼하고 못받은 양육비를 10년 후에 다시 청구할 수 있나요? ...(생략)	과거에 못받은 양육비인 과거양육비를 청구할 수 있습니다. 아직 미성년 기간이 남아있다면, 장래양육비도 청구할 수 있습니다.

III. 본론2

1. 모델 실험 과정

본 연구에서는 Llama 3.1 모델을 기반으로 한 대규모 언어모델(LLM)의 효율적인 학습을 위해, 경량화 파인튜닝 기법(LoRA: Low-Rank Adaptation)을 적용하였다. LoRA는 기존의 거대 언어모델을 전체 가중치 업데이트 없이, 특정 부분의 가중치 행렬을 저랭크(Low-Rank)로 분해하여 학습하는 방법으로, 학습 속도를 향상시키고 GPU 메모리 사용량을 크게 절감할 수 있다.

LoRA 적용 시 모델의 성능과 자원 효율성을 조절하기 위해 [r] (Rank) 값과 [lora_a

lpha] 파라미터를 세밀하게 설정하였다.

[r] 값은 가중치 행렬의 분해 차원을 결정하여 학습 가능한 파라미터의 수를 조절하는 역할을 한다.

[lora_alpha] 값은 LoRA의 스케일링 계수로, 초기 학습 단계에서의 학습 속도 및 모델 수렴 안정성에 직접적인 영향을 미친다.

본 연구에서는 사전 검토된 유사 연구의 하이퍼파라미터 설정을 참고하여, [r]과 [lora_alpha] 값을 조정하면서 모델의 학습 시간과 성능 간의 균형을 최적화하였다. 또한, 학습률(learning rate)은 $5e-5$ 에서 점차 감소시키는 방식으로 조정하였으며, 그 결과 $1.5e-5 \sim 2e-5$ 구간에서 가장 안정적이고 우수한 학습 성능을 보였다.

학습 과정에서는 Epoch 횟수를 1회, 2회, 3회로 나누어 모델의 수렴 경향을 비교하였다. 그 결과, Epoch 1회에서는 모델이 충분히 학습되지 않아 응답의 일관성이 낮았으며, Epoch 3회에서는 과적합(overfitting) 현상으로 인해 일부 응답이 불안정하게 출력되었다. 반면, Epoch 2회에서 가장 안정적이고 명확한 출력 결과를 나타내어, 본 모델의 최적 학습 반복 횟수로 설정하였다.

이와 같은 실험 과정을 통해, 본 연구는 Llama 3.1 모델의 경량화 학습 구조에서 메모리 효율성과 성능 간의 균형점을 도출하였으며, 이를 기반으로 법률 상담 질의응답 모델의 정확도와 추론 속도를 향상시킬 수 있었다.

2. 훈련 방법 및 시간

모델 학습은 Google Colab Pro 환경에서 수행되었으며, NVIDIA A100 GPU를 활용하여 총 2 Epoch 동안 Fine-Tuning을 진행하였다. 전체 학습 시간은 약 4시간 30분이 소요되었으며, 학습 진행 중에는 50 Step마다

train_loss 값을 출력하여 모델의 수렴 정도를 주기적으로 관찰하였다.

학습 완료 후에는 출력된 손실 값(train_loss)과 각 단계별 로그(log)를 분석하여 전체적인 학습 진행도와 안정성을 평가하였다. 이러한 지표를 통해 모델이 안정적으로 수렴하였는지, 과적합(overfitting)이나 학습 불안정성이 존재하는지를 확인할 수 있었다.

IV. 본론 3

1. 문장 정제

본 실험의 결과 분석 과정에서 일부 한계점이 확인되었다. 우선, 불필요한 문장과 과도한 상세 설명으로 인해 각 단계별 기술이 다소 장황하게 표현되었으며, 이로 인해 핵심 내용의 전달력이 저하되고 가독성이 떨어지는 문제가 있었다. 또한, 문장 구조가 다소 기계적으로 배열되어 자연스러운 흐름과 논리적 연결성이 부족한 부분이 존재하였다. 이 문제를 해결하기 위해 문장을 출력하는 과정에서 깔끔한 문장을 완성하기 위하여 추가로 문장 정제 모듈을 구성하였다.

SequenceMatcher 알고리즘을 이용해 문장 간 유사도를 계산하고 반복적으로 출력되는 오류를 찾아내어 제거한다. 그다음 문장 구조를 정제하여 문장의 가독성을 향상시키고 문장의 끝마침과 줄바꿈, 기호등을 구분하여 문단 또는 문장의 구성도를 높인다.

2. 실험 결과

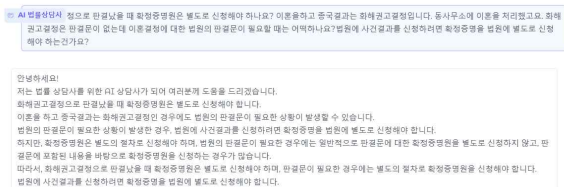


그림 6. 학습된 모델로 실험한 법률상담

본 연구의 실험 결과, 위 그림6.처럼 Llama 3.1 모델 중 상대적으로 규모가 작은 8B 파라미터 모델을 사용하였으며, 학습 데이터의 크기 또한 53,500건으로 제한적이었다. 이에 따라 상업적으로 활용되고 있는 대형 인공지능 챗봇 수준의 문장 완성도에는 미치지 못하였으나, 법률 상담 분야에 한정하여 볼 때는 보통 이상 수준의 응답 정확도를 나타내는 것을 확인할 수 있었다. 다만, 실제 법률 전문가의 상담에 비해 세부적이고 상황 맞춤형 대응 측면에서는 한계가 존재하는 것으로 보인다. 향후 더 많은 파라미터를 가진 Llama 3.1 70B 또는 405B 모델을 활용하여 Fine-tuning을 진행하거나, 보다 방대한 규모와 정제된 데이터셋을 적용한다면, 본 연구의 모델은 한층 높은 성능과 신뢰도를 보이는 법률 상담 인공지능으로 발전할 수 있을 것으로 판단된다.

V. 결 론

본 연구에서는 Llama 3.1 기반의 대규모 언어모델(LLM)을 Fine-Tuning하여, 기존 법률상담의 시간적·공간적 제약과 높은 비용 문제를 개선할 수 있는 AI 법률상담 시스템을 구현하였다. 기존의 법률상담은 변호사 또는 전문 상담원과의 대면 상담에 의존하여 접근성이 낮고, 이용자의 시간과 경제적 부담이 컸다. 이를 해결하기 위해 본 연구에서는 Gradio를 활용한 웹 기반 인터페이스와 LoRA 경량화 기법을 적용한 Llama 3.1 모델을 결합하여, 사용자가 온라인 환경에서 언제든지 법률 상담을 받을 수 있는 플랫폼을 구축하였다. 학습 과정에서는 A100 GPU 환경에서 2 Epoch, 약 4시간 30분의 Fine-Tuning을 진행하였고, 50 Step마다 train_loss를 출력하며 모델의 수렴 과정을 검증하였다. 그 결과, 학습률 $1.5e-5 \sim 2e-5$ 구간에서

가장 안정적인 성능을 보였으며, Epoch 2회에서 최적의 학습 결과를 확인하였다. 완성된 시스템은 자연어 기반 질의응답이 가능하며, 문장 정제 및 중복 제거 기능을 통해 가독성과 응답 품질을 향상시켰다. 이를 통해 사용자는 법률지식이 부족하더라도 AI를 통해 신속하고 효율적인 법률 자문을 받을 수 있게 되었으며, 이는 법률 서비스의 접근성과 형평성을 높이는 데 기여할 수 있다. 그러나 본 연구에는 몇 가지 한계점이 존재한다. 우선 학습 데이터가 주로 민사법 중심으로 구성되어 있어 형사, 행정, 가사 등 다양한 법률 분야를 포괄하지 못한다는 점이 있다. 또한 AI가 제공하는 상담 결과는 참고용 수준에 머물러 있으며, 실제 법적 판단이나 소송 대리나 같은 전문적 판단을 완전히 대체하기는 어렵다. 향후 연구에서는 보다 다양한 법률 분야의 데이터를 수집하고, 응답의 신뢰도 평가 및 사실 검증 알고리즘을 강화하여 모델의 법적 정확성을 향상시킬 예정이다. 또한 시각적 학습 지표와 피드백 시스템을 도입하여 학습 효율성을 정량적으로 평가하고, 음성 입력 및 사례 기반 법률 데이터베이스를 연동함으로써 사용자 친화적인 지능형 법률상담 서비스로 발전시킬 계획이다. 이러한 연구의 확장은 향후 AI 기반 법률 지원 기술의 실질적 활용 가능성을 높이고, 사회적 법률 접근성의 격차를 완화하는 데 기여할 것으로 기대된다.

참 고 문 헌

- [1] Statistics for 2024 Consultation at Korea Family Law Counseling Center web site, https://lawhome.or.kr/webbook/2024_counselstatistics/res/pages/pages.pdf
- [2] Meta Platforms, Inc., “Introducing Llama 3.1: Our most capable models to date,” AI at Meta Blog, Jul. 23 2024. [Online]. <https://ai.meta.com/blog/meta-llama-3-1/>
- [3] H. Touvron, C. Raffel, D. Driess, L. Martin, J. Lucas, L. Bosquet, ... & Meta AI Llama Team, “The Llama 3 Herd of Models,” arXiv:2407.21783, 2024. [Online]. Available: <https://arxiv.org/abs/2407.21783>
- [4] E. J. Hu, Y. Shen, P. Wallis, Z. Allen Zhu, Y. Li, S. Wang, L. Wang, W. Chen, “LoRA: Low Rank Adaptation of Large Language Models,” arXiv:2106.09685, 2021. <https://arxiv.org/abs/2106.09685>
- [5] J. Wei, M. Bosma, V. Y. Zhao, K. Guu, A. W. Yu, B. Lester, N. Du, A. M. Dai, Q. V. Le, “Finetuned Language Models Are Zero-Shot Learners,” arXiv:2109.01652, 2021. [Online]. <https://arxiv.org/abs/2109.01652>